

Plataforma Helios — Documento de Arquitectura

Nordia Bank · Dirección de Datos e IA

Versión del documento: 4.2 · Clasificación: Interno · Última revisión: 12 de marzo de 2026

Responsable: Oficina de Arquitectura de Datos (ODA)

1. Propósito y alcance

Helios es la plataforma interna de datos de Nordia Bank. Da servicio a los dominios de Riesgos, Fraude, Marketing Analítico, Tesorería y Cumplimiento. Este documento describe la arquitectura objetivo de la versión 4 y las decisiones estructurales que la sustentan.

Helios **no** es una plataforma de cara a cliente. Todos los consumidores son equipos internos de Nordia Bank o filiales del grupo con acuerdo de tratamiento firmado. Cualquier exposición externa requiere aprobación expresa del Comité de Arquitectura (CAT) y queda fuera del alcance de este documento.

2. Componentes principales

La plataforma se organiza en cuatro servicios troncales, cada uno con su propio ciclo de despliegue:

Kestrel — Ingesta. Recoge eventos y ficheros de los sistemas origen. Soporta tres modos: streaming (Kinesis Data Streams), micro-batch cada 15 minutos y carga masiva diaria. Kestrel escribe siempre en la zona *raw* del lago sin transformación, preservando el payload original y añadiendo metadatos de linaje (`_ingest_ts`, `_source_system`, `_schema_version`).

Vela — Orquestación. Motor de orquestación basado en Apache Airflow 2.9 desplegado sobre EKS. Gestiona los DAG de transformación entre zonas *raw*, *curated* y *serving*. Vela impone un SLA interno de frescura: ningún dataset de la zona *curated* puede tener más de 6 horas de retraso respecto a su origen sin generar una alerta automática.

Aria — Feature Store. Almacén de características para modelos de machine learning, referido en documentación antigua como FSA (Feature Store Aria). Aria mantiene dos planos: *offline* sobre Iceberg para entrenamiento y *online* sobre DynamoDB para inferencia en tiempo real. La latencia p99 comprometida en el plano online es de 25 milisegundos.

Halo — Serving API. Capa de exposición de datos vía REST y GraphQL. Es el único punto de acceso programático permitido para aplicaciones. El acceso directo al lago desde aplicaciones está prohibido desde la versión 3.0.

3. Zonas del lago de datos

Zona	Formato	Retención de datos	Acceso
raw	Formato original (JSON, CSV, Avro)	30 días	Solo Kestrel y operadores
curated	Apache Iceberg sobre S3	7 años	Analistas y procesos
serving	Iceberg + DynamoDB	90 días	Halo y Aria
archive	Parquet en S3 Glacier	10 años	Solo bajo solicitud formal

La retención de la zona *raw* es de 30 días naturales. Este valor fue reducido desde los 90 días originales en la revisión 4.0 por motivos de coste, tras verificar que ningún proceso de reproceso histórico dependía de ventanas superiores.

4. Registro de decisiones de arquitectura (ADR)

ADR-011 — Iceberg como formato de tabla. Se adopta Apache Iceberg frente a Delta Lake y Hudi. Motivo principal: soporte nativo de evolución de esquema y *time travel* sin dependencia de un motor concreto, lo que preserva la portabilidad entre Athena, Spark y Trino. Fecha: junio de 2025.

ADR-014 — Kinesis frente a Kafka gestionado. Se descarta Amazon MSK y se adopta Kinesis Data Streams. El criterio decisivo no fue el rendimiento sino el coste operativo: el equipo de plataforma tiene 6 personas y MSK exigía capacidad dedicada de administración de brokers. El coste anual estimado de la alternativa MSK era un 34% superior una vez incluido el esfuerzo operativo. Fecha: agosto de 2025.

ADR-019 — Prohibición de acceso directo al lago. Toda aplicación debe consumir a través de Halo. Motivo: trazabilidad de accesos a efectos de auditoría y capacidad de aplicar cuotas. Excepción única: los cuadernos de análisis exploratorio del equipo de Ciencia de Datos, que acceden a la zona *curated* en modo lectura mediante credenciales temporales de 8 horas. Fecha: octubre de 2025.

ADR-023 — Multi-región activo-pasivo. La región principal es eu-west-1 (Irlanda). La región secundaria es eu-central-1 (Fráncfort), en modo pasivo con replicación asíncrona. El RPO objetivo es de 15 minutos y el RTO objetivo de 4 horas. Se descartó el modo activo-activo por el coste de resolución de conflictos en el plano online de Aria. Fecha: enero de 2026.

ADR-027 — Modelos de lenguaje vía pasarela corporativa. Cualquier consumo de LLM desde componentes de Helios debe realizarse a través de la pasarela corporativa Lumen, nunca contra endpoints de proveedor directamente. Lumen centraliza autenticación, registro de prompts, control de coste por equipo y filtrado de datos sensibles. Fecha: febrero de 2026.

5. Entornos

Existen tres entornos: dev, pre y pro. Los datos de producción no pueden copiarse a dev bajo ninguna circunstancia. El entorno pre puede contener datos de producción anonimizados mediante el pipeline de ofuscación Trama, que aplica pseudonimización sobre 14 campos catalogados como identificadores directos.

Los despliegues a pro se realizan en ventanas de martes y jueves de 07:00 a 09:00 CET. Fuera de esa ventana solo se admiten despliegues clasificados como *hotfix* con aprobación del responsable de guardia.

6. Observabilidad

La plataforma emite métricas a Prometheus y trazas a OpenTelemetry, con visualización en Grafana. Cada servicio publica obligatoriamente cuatro señales: tasa de peticiones, tasa de error, latencia p50/p95/p99 y saturación de recursos.

El presupuesto de error (*error budget*) mensual de Halo es del 0,1% de las peticiones, equivalente a un objetivo de disponibilidad del 99,9%. Si se consume más del 50% del presupuesto antes del día 15 del mes, se congelan automáticamente los despliegues de funcionalidad hasta el mes siguiente.

7. Dependencias externas

Helios depende de tres sistemas fuera del perímetro de la Dirección de Datos: el bus corporativo de eventos (equipo de Integración), el directorio de identidades Okta (equipo de Seguridad) y la pasarela Lumen (equipo de IA). Las incidencias con origen en estas dependencias se escalan según el procedimiento descrito en el runbook de incidencias.

8. Hoja de ruta

Las iniciativas aprobadas para 2026 son: migración de Airflow 2.9 a 3.x en el tercer trimestre, incorporación de un catálogo de datos con linaje columna a columna, y sustitución del plano online de Aria por una solución de menor latencia si el p99 comprometido baja de 25 a 10 milisegundos. Ninguna de estas iniciativas tiene todavía presupuesto asignado formalmente.